

Herramienta de Regresión Auditada para Estimar Emisiones de CO₂ de Vehículos:

Métricas, Auditoría y Corrección de una Disparidad

Problema, Datos y Decisión

La herramienta predice *CO₂ Emissions(g/km)*, apoyando la decisión de un fabricante de estimar el CO₂ de una configuración nueva *antes* de la homologación oficial, para decidir si cumplirá el límite de flota. El error se expresa en g/km. Los datos son públicos (*CO₂ Emission by Vehicles*, Podder, s.f.; Gobierno de Canadá, 2026): 7,385 filas, once predictoras. Cuatro columnas de consumo de combustible se marcaron como fuga (mismo ensayo que el CO₂; $R^2 \geq 0.98$ por tipo de combustible), y *Fuel Type* se usó como subgrupos.

Métricas e Interpretación

Se entrenaron tres modelos con la misma partición (75/25, semilla fija) y preprocesamiento ajustado solo con entrenamiento, en un Pipeline de scikit-learn (Pedregosa et al., 2011): referencia trivial, regresión lineal y Random Forest (300 árboles). La Tabla 1 muestra sus métricas de prueba, ya con el defecto de datos de la sección siguiente corregido.

Tabla 1: MSE, RMSE y R^2 de los tres modelos (conjunto de prueba, $n = 1,498$)

Modelo	MSE (g/km) ²	RMSE (g/km)	R ² prueba	R ² entrenamiento
Referencia (media)	3,681.12	60.67	-0.0001	0.0000
Regresión lineal	519.73	22.80	0.8588	0.8559
Random Forest	253.03	15.91	0.9313	0.9519

Nota. CO₂ medio de prueba = 252.17 g/km; desviación estándar = 60.67 g/km ($n = 1,498$).

El RMSE de Random Forest (15.91 g/km, $\approx 6.3\%$ del CO₂ medio) es su error típico en g/km; su R^2 (0.9313) es la proporción de variación explicada. Una sola métrica no basta: la referencia tiene RMSE 60.67 g/km —moderado en apariencia— pero $R^2 \approx 0$ (no explica nada; es solo la dispersión natural del CO₂), y el R^2 solo no dice si el error basta para decidir. Random Forest

reduce el RMSE 73.8% frente a la referencia; la regresión lineal, 62.4%. El R^2 de entrenamiento y prueba difiere solo 0.0206 (RF) y -0.0029 (lineal): sin sobreajuste.

Análisis de Residuos

La Figura 1 muestra los residuos (real menos predicho) contra sus predichos y su distribución. El residuo medio por decil va de -1.15 a $+3.72$ g/km, sin curvatura; la dispersión crece levemente en valores altos ($\approx 13\text{--}15$ g/km frente a $\approx 17\text{--}20$). El histograma está casi centrado en cero (media 0.35 g/km), con colas pesadas. El mayor residuo ($+114.5$ g/km) es el único vehículo de 16 cilindros del conjunto de datos —sin ejemplos en entrenamiento—, evidencia de extrapolación. Buscando tecnologías fuera de las predictoras: los híbridos ($n=26$) sobreestiman 19.70 g/km ($t=-5.83$) y los de tracción integral subestiman de 4.54 a 8.02 g/km (t entre 3.12 y 5.05); las cinco especificaciones permitidas no capturan la propulsión ni la tracción.




Figura 1

Residuos del modelo final (Random Forest) contra valores predichos, e histograma de residuos, sobre el conjunto de prueba.

Hallazgos de la Auditoría y Corrección

La herramienta se auditó con la Skill *auditoria-modelos* de Claude Code (Anthropic, 2026), construida en la Tarea 4.1. Su v1.4, sin modificar, dejó 6 de 15 subcriterios en “no se puede determinar” por ser solo de clasificación; se extendió a la v2.0 con criterios de regresión, en un commit aparte. La primera auditoría dio un solo hallazgo: V4.2 en FALLA —el diésel tenía un

RMSE 1.24 veces el global, sobre un umbral de 1.10—. La causa: 292 filas eran el mismo vehículo con distinta capitalización en marca/modelo (p. ej., “Colorado ZR2 4WD” y “COLORADO ZR2 4WD”), sin detectar por la eliminación de duplicados; 98 filas de prueba tenían así su gemelo en entrenamiento. La corrección aplicada normaliza marca y modelo a mayúsculas antes de eliminar duplicados y dividir (Tabla 2).

Tabla 2: Random Forest antes y después de corregir los duplicados con distinta capitalización

Métrica	Antes	Después
n (conjunto de prueba)	1,571	1,498
RMSE global (g/km)	15.37	15.91
R ² de prueba	0.9334	0.9313
RMSE del subgrupo diésel (g/km)	19.06	15.97
Razón diésel / global	1.2407	1.0040
V4.2 (razón ≤ 1.10)	FALLA	PASA

Nota. El RMSE global sube porque el “antes” era optimista (incluía gemelos ya vistos en entrenamiento). La segunda auditoría, sobre el modelo corregido, dio los 15 subcriterios en PASA; la Skill señaló que la causa se encontró observando la prueba, pero razonó que la corrección —una regla de limpieza aplicada por igual antes de la partición— no es el ajuste que el criterio de fuga prohíbe.

Limitaciones y Condiciones de No Uso

El modelo final se entrenó con CO₂ entre 99 y 488 g/km, cilindrada 0.9–8.4 L y cilindros de 3 a 12 (sin 16, ver Bugatti Chiron); no extrapolar fuera de estos rangos ni a categorías ausentes. La gasolina premium queda más cerca del umbral de disparidad (razón 1.08); TWO-SEATER y SUV-STANDARD tienen el mayor RMSE (≈ 20 g/km); híbridos y tracción integral mantienen su sesgo, sin corregir. Con el tiempo podría cambiar la relación cilindrada–CO₂, proporción de híbridos, transmisiones y método de ensayo; sin año, no se mide. No sustituye la homologación; no usar si la estimación queda a menos de un RMSE del límite de flota (≈ 16 –20 g/km), en híbridos, eléctricos, gas natural, tracción integral o alto desempeño, fuera de rango, en decisiones automáticas sin revisión humana, ni para atribuir causas.

Referencias

- Anthropic. (2026). *Extend Claude with skills*. Claude Code Docs.
<https://code.claude.com/docs/en/skills>
- Gobierno de Canadá. (2026). *Fuel consumption ratings* [Conjunto de datos]. Open Government Portal. <https://open.canada.ca/data/en/dataset/98f1a129-f628-4ce4-b24d-6f16bf24dd64>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Podder, D. (s.f.). *CO2 emission by vehicles* [Conjunto de datos]. Kaggle.
<https://www.kaggle.com/datasets/debajyotipodder/co2-emission-by-vehicles>